

NIKHIL MANKALI

AI/ML Ingenieur | AWS-zertifizierter Cloud Practitioner

☎ +4917613428740 @ mankalinikhil9@gmail.com 🔗 <https://www.linkedin.com/in/nikhil-mankali>
🌐 <https://d1t6fdfo6c7b31.cloudfront.net> 📍 Siegen, DE (Umzugsbereit)



ZUSAMMENFASSUNG

AI/ML Ingenieur mit Erfahrung in der Entwicklung und Bereitstellung produktionsreifer KI- und LLM-basierter Anwendungen, mit dem Fokus, geschäftlichen Nutzen durch intelligente Systeme zu liefern. Versiert in der Entwicklung von APIs, der Integration von maschinellen Lernmodellen in Anwendungen und der Bereitstellung skalierbarer Lösungen auf AWS und Azure. Kompetent in der Erstellung KI-gesteuerter Funktionen wie Chatbots, Entscheidungsunterstützungstools und automatisierten Arbeitsabläufen. Starker Fokus auf die Übersetzung geschäftlicher Anforderungen in zuverlässige, wartbare und benutzerfreundliche KI-Systeme.

FÄHIGKEITEN

Programmierung

Python, C++, C, SQL, Bash, HTML, CSS, JavaScript, JSON, YAML

ML/DL Frameworks

PyTorch, TensorFlow, HuggingFace, OpenCV, NumPy, Pandas, Matplotlib, Scikit-learn, Seaborn, Tensorboard, Weights & Biases, MLFlow

Computer Vision

Objekterkennung, Segmentierung, Anomalieerkennung, OOD-Erkennung, Adversarielle Robustheit, Unsicherheitsschätzung, Luftbildwahrnehmung, Bildverarbeitung

LLM/GenAI

NLP, LLMs, Prompt Engineering, Transformers, LLM Finetuning, Model Serving, OpenAPI, Claude Code, Copilot, Whisper, Ollama

RAG & Agentic KI Frameworks

LangChain, LangGraph, Amazon Bedrock Agentcore, FastMCP, FastAPI, Streamlit

Datenbanken & Abrufsysteme

PostgreSQL, MongoDB, FAISS, Neo4j, ChromaDB, Azure AI Search

Cloud & Deployment

AWS, Azure, Docker, Kubernetes, Grafana, Prometheus, Terraform (IaC), CloudFormation(IaC), GitHub, GitHub Actions, GitLab, HPC

BERUFSERFAHRUNG

05/2025 - Aktuell

Siegen, Deutschland

KI-Entwickler - AgenticAI, RAG Systeme, LLMOps

Unabhängige Projekte, Machbarkeitsstudien

- **MCP Servers** – Erstellung produktionsreifer MCP-Server mit FastMCP für die lokale und Remote-Bereitstellung. Beispiele: MCP-Server für das Ausgabenmanagement, MCP-Server für die Audio-Transkription mit Whisper.
- **RAG Based Portfolio Website** - Eine Portfolio-Website mit einem serverlosen RAG-Chatbot unter Verwendung von AWS (Lambda, Bedrock, S3, API Gateway, CloudFront) und einem React-Frontend erstellt.
- **Smart Receipt Scanner** - Entwicklung einer serverlosen Webanwendung zum Scannen von Quittungen mit AWS (Lambda, S3, DynamoDB, Cognito) und React-Frontend, inklusive OCR-Textauszug, Authentifizierung für mehrere Benutzer und Budgetanalysen mit Ausgabekategorisierung.
- **RAG Chatbot** - Entwicklung eines produktionsreifen retrieval-augmentierten Q&A-Systems mithilfe von Azure OpenAI, Azure AI Search und FastAPI; erzielte eine Glaubwürdigkeit von 0,89 (RAGAS) und verbesserte die Antwortrelevanz um 23% durch A/B-Tests. Bereitgestellt als containerisierte Mikrodienst auf Azure Container Apps mit automatisierten CI/CD-Pipelines.
- **Web Scraper** - Entwicklung eines vollwertigen Scrapers zur Auswahl von Forschungsarbeiten über die Springer API, inklusive mehrsprachiger PDF-Newsletter mit KI-generierten Zusammenfassungen via ChatGPT-API, sicherer Authentifizierung, Übersetzung und barrierefreier PDF-Erstellung mit Inhaltsverzeichnis.
- **Tech-Stack:** Python, PyTorch, LangChain, LangGraph, Strands, FastAPI, FastMCP, Docker, AWS, Azure, React, HTML, CSS.

11/2023 - 04/2025

Ingolstadt, Deutschland

Wissenschaftlicher Mitarbeiter - Computer Vision, Anomalieerkennung

Fraunhofer-Institut für Verkehrs- und Infrastruktursysteme IVI

- Entwicklung und Implementierung eines KI-basierten Anomalieerkennungssystems für die Luftbildwahrnehmung, was zuverlässige Entscheidungen in realen Anwendungen ermöglicht.
- Validierung des Moduls in realen Drohnenflügen; erfolgreich unbekannte Objekte (z.B. Hunde), die in Trainingsdatensätzen nicht vorhanden sind, identifiziert.
- Integration von Unsicherheitsabschätzungen in die CV-Pipeline zur Verbesserung der Modellleistung, Robustheit und Zuverlässigkeit in realen Szenarien.
- Entwicklung und Pflege skalierbarer produktionsreife End-to-End KI-Pipelines für Datenverarbeitung, Modelltraining, Evaluierung und Bereitstellung mit Python, Docker und Kubernetes.
- Beitrag zu ML-Modellen und -Werkzeugen, die Teil interner Projektvorschläge und Finanzierungsanträge für UAM-Forschung waren.
- **Tech-Stack** - Python, PyTorch, HuggingFace, Docker, Kubernetes, Grafana, Bash, Git, CI/CD.

BERUFSERFAHRUNG

06/2023 - 09/2023

Ingolstadt, Deutschland

Wissenschaftlicher Mitarbeiter – Data Science

Technische Hochschule Ingolstadt

- Erhebung und Bereinigung von Datensätzen mit verschiedenen Ansichtsarten (top-down, frontal, schräg) zur Erstellung eines einheitlichen Luftbilddatensatzes.
- Ausgewogene Abdeckung des Datensatzes sichergestellt und die Annotierungsqualität für das Training von Objekterkennungs- und Segmentierungsmodellen gewährleistet.
- Erreichte gesteigerte Genauigkeit und Generalisierung nachgelagerter Computer Vision-Aufgaben am Fraunhofer IVI.
- **Tech-Stack** - Python, PyTorch, Bash, Git, CI/CD.

08/2022 - 06/2023

Siegen, Deutschland

Wissenschaftlicher Mitarbeiter – Computer Vision

Computer Vision Abteilung – Universität Siegen

- Untersuchte die adversarielle Robustheit von CV-Modellen durch Simulation von Angriffen auf Graustufen-, RGB- und 3D-Voxel-Daten.
- Verbesserte die Robustheit mit adversarialem Training: FGSM-Genauigkeit auf 95%, PGD auf 46% erhöht.
- **Tech-Stack** - Python, PyTorch, SLURM, Git, Bash, Verteiltes Rechnen.

PRAKTIKUM

06/2023 - 09/2023

Ingolstadt, Deutschland

Praktikant im Bereich Computer Vision

Fraunhofer-Institut für Verkehr und Infrastruktursysteme IVI

- Analyse und Harmonisierung von über 15 Luftbilddatensätzen, die für das Training von CV-Modellen verwendet werden, mit Fokus auf Annotierungsformat, Klassifizierungsverteilung und Eingangsnormalisierung.
- Erstellte Skripte zur Automatisierung der Label-Konvertierung und Verbesserung der Kompatibilität mit Frameworks für Objekterkennung und Segmentierung.
- Verfaste interne Dokumentationen zur Erstellung von Docker-Images, zur Bereitstellung über kubectrl und zur Nutzung von Octane-Simulationen, die nun als Einarbeitungsunterlagen verwendet werden.
- Arbeitete mit cross-funktionalen Teams zusammen, um KI-Module in bestehende Arbeitsabläufe zu integrieren, und unterstützte dabei Tests, Bereitstellung und Anwendungsszenarien in der Praxis.
- **Tech-Stack** - Python, PyTorch, Docker, Kubernetes, Git, Bash, Objekterkennung, Segmentierung.

MASTERARBEIT

Pixelweise Erkennung von Verteilung außerhalb der Daten bei der semantischen Segmentierung von Luftbildern unter Verwendung normalisierender Flussnetzwerke zur Negativmerkmalsynthese

- Entwickelte eine Methode zur Erkennung bis dato unbekannter Muster unter Verwendung einer normalisierenden Fluss-basierten Merkmalmodellierung, mit Fokus auf Modellzuverlässigkeit und -verallgemeinerung.
- Durchführte quantitative Bewertungen und Fehlersanalysen mit Segmentierungspipelines und statistischen Metriken.
- Verbesserte die Robustheit und Zuverlässigkeit der Modelle unter realen Bedingungen.
- [[Link zu meiner Dissertation](#)]

BILDUNG

07/2025 - 10/2025

Hamburg, Deutschland

AWS re/Start Cloud Computing Bootcamp

neuefische GmbH – Schule und Pool für digitale Talente

- Networking, Linux-Systeme, Terraform, Skripting, Docker, Kubernetes, AWS-Dienste

10/2020 - 03/2024

Siegen, Deutschland

M.Sc. Mechatronik

Universität Siegen

Durchschnittsnote **1,8 / 4**

- **Fächer:** Software Engineering (C++, Python, SQL), Unsupervised Deep Learning, Computer Vision, Künstliche Intelligenz, Automatisierung und industrielle Kommunikation, Projektmanagement
- **Masterarbeit:** Pixelweise Erkennung von Verteilung außerhalb der Daten bei der semantischen Segmentierung von Luftbildern unter Verwendung normalisierender Flussnetzwerke zur Negativmerkmalsynthese
- **Studienarbeit:** Bewertung und Verbesserung der Robustheit von tiefen neuronalen Netzen durch adversariales Training

06/2015 - 05/2019

Hyderabad, Indien

B.Tech. Maschinenbau

CVR College of Engineering

Durchschnittsnote **9,63 / 10**

- **Fächer:** Technische Mathematik, Fluidmechanik, Mechanik, Verbrennungsmotoren, CAD, CNC.

ZERTIFIKATE

AWS Zertifizierter Cloud Practitioner (CLF-C02)

AWS [[Link](#)]

SPRACHEN

Deutsch

Fortgeschritten (B1/B2)



Englisch

Fließend (C1/C2)

